

Departamento de Estadística e I.O.

Máster en Estadística Aplicada



**UNIVERSIDAD
DE GRANADA**

**MODELOS DE RESPUESTA DISCRETA
APLICACIONES BIOSANITARIAS**

Tema 3

Guía de trabajo autónomo

Profesores

Ana María Aguilera del Pino

Manuel Escabias Machuca

Título original: Modelos de Respuesta Discreta. Aplicaciones Biosanitarias.
Guía de Trabajo Autónomo del Tema 3

© Los profesores

Todos los derechos reservados. Esta publicación es de uso personal del alumno y no puede ser reproducida, ni registrada, ni transmitida en ninguna forma ni por ningún medio, sin el permiso de los autores

Índice general

1. Guía de Trabajo Autónomo del Tema 3	1
1.1. Justificación del Tema 3	1
1.2. Objetivos del Tema 3	2
1.3. Actividades del Tema 3	2

Capítulo 1

Guía de Trabajo Autónomo del Tema 3

Para asimilar los contenidos del Tema 3 el alumno debe estudiar los apuntes de teoría del tema y realizar las actividades de trabajo autónomo de esta guía. Estas actividades tienen como objetivo facilitar el autoaprendizaje del alumno y la consecución de los objetivos del tema. Es conveniente que el alumno las trabaje individualmente y plantee en el foro sus posibles dudas e inquietudes relacionadas con las mismas.

1.1. Justificación del Tema 3

Este capítulo está dedicado al estudio de las distintas formas de introducir las variables categóricas como variables explicativas en los modelos de regresión logística. Como es usual en modelización estadística, se comenzará por la formulación del modelo e interpretación de sus parámetros en forma de cocientes de ventajas. Dado que las variables categóricas aparecen en el modelo en forma de variables numéricas asociadas a sus categorías (variables de diseño) el problema de estimación de parámetros, contrastes de hipótesis y validación y selección de modelos, se llevará a cabo mediante las metodologías estudiadas en el Tema 2. Para poner en práctica los conocimientos adquiridos se realizarán ajustes de modelos logit con datos reales con variables explicativas tanto cuantitativas como cualitativas, mediante el uso del software libre R.

1.2. Objetivos del Tema 3

- Estudiar la formulación del modelo de regresión logística a partir de una o varias variables categóricas relacionadas.
- Interpretar la relación entre la variable de respuesta y cada variable categórica en términos de cocientes de ventajas.
- Formular modelos logit con variables explicativas tanto cuantitativas como cualitativas, estimar sus parámetros, seleccionar variables, hacer inferencia sobre los parámetros estimados, validar el modelo e interpretar los resultados.
- Implementar los modelos logit estudiados con el software R para poder relizar aplicaciones con datos biomédicos o en cualquier otro campo de interés.

1.3. Actividades del Tema 3

1. Haga una lectura comprensiva de los apuntes del Capítulo 3 para obtener una visión global del tema.
2. Explique detalladamente las diferencias en la interpretación de los parámetros asociados al modelo logit con una única variable categórica dependiendo de si se usa el método parcial o el método marginal de codificación de la variable categórica.
3. Formule teóricamente el modelo logit con una única variable categórica explicativa codificada de acuerdo al método parcial tomando como categoría de referencia la última. Observe las diferencias en la interpretación de los parámetros en términos de cocientes de ventajas respecto a la formulación de los apuntes en la que la categoría de referencia es la primera.
4. A una muestra de individuos se les preguntó su opinión sobre una ley de legalización del aborto (a favor o en contra). El modelo considerado para explicar la probabilidad p de estar a favor de legalizar el aborto en términos de las variables explicativas sexo (mujer, hombre), religión (protestante, católica, judía) y afiliación política (demócrata, republicana, independiente) es de la forma

$$\ln \left[\frac{p_{hij}}{1 - p_{hij}} \right] = \alpha + \beta_h^S + \beta_i^R + \beta_j^P,$$

con valores estimados

$$\hat{\alpha} = 0,62, \quad \hat{\beta}_1^S = 0,08, \quad \hat{\beta}_2^S = -0,08, \quad \hat{\beta}_1^R = -0,16, \quad \hat{\beta}_2^R = -0,25,$$

$$\hat{\beta}_3^R = 0,41, \quad \hat{\beta}_1^P = 0,87, \quad \hat{\beta}_2^P = -1,27, \quad \hat{\beta}_3^P = 0,40.$$

- a) Justificar el método de codificación utilizado y dar para cada variable categórica una tabla con los valores de las variables del diseño asociadas (columnas) para cada categoría (filas).
 - b) Interpretar como las ventajas de estar a favor del aborto dependen del sexo, de la religión y de la afiliación política.
 - c) Encontrar la probabilidad estimada de estar a favor del aborto legal para hombres católicos y republicanos, por un lado, y para mujeres judías y demócratas por otro.
 - d) Redefinir los parámetros con restricciones $\beta_1^S = \beta_1^R = \beta_1^P = 0$, dando en forma de tablas los valores de las variables del diseño asociadas. Estimar los nuevos parámetros y explicar como interpretarlos.
5. Formular un modelo logit sin interacción y otro con interacción para explicar una variables de respuesta binaria Y en función de tres variables explicativas, dos de ellas categóricas, denotadas por $A(A_1, A_2, A_3)$ y $B(B_1, B_2)$, y la otra cuantitativa, denotada por X (usar el método parcial de codificación de las variables de diseño). Obtener para este modelo la expresión de los cocientes de ventajas de respuesta $Y = 1$ para cada categoría de cada variable explicativa categórica con respecto a la de referencia y controlando fijas las demás. Obtener también la expresión del cociente de ventajas de respuesta $Y = 1$ cuando se incrementa k unidades la variable cuantitativa X y se controlan fijas las dos variables categóricas A y B . Proporcionar finalmente intervalos de confianza aproximados para estos cocientes de ventajas, a partir de la distribución normal asintótica de los logaritmos de sus estimadores MV que son combinaciones lineales de los estimadores MV de los parámetros del modelo.
6. Elabore sus propios apuntes sobre como se realiza la estimación, inferencia y selección paso a paso de modelos logit con variables explicativas categóricas con R, y utilícelos para resolver los ejercicios que se proponen a continuación. Plantee cualquier tipo de duda o comentario sobre su resolución en el foro de este tema.

7. Para estudiar si el desarrollo de una enfermedad coronaria (EC) está influenciado por el número de cigarrillos diarios que fuma una persona, su tipo de vida (A y B) y su presión sanguínea (PS), se han tomado 16 muestras independientes de individuos, una para cada una de las posibles combinaciones de niveles de las tres variables explicativas.

			Nº cigarrillos			
			0	1-20	21-30	> 30
PS $\geq$ 140	Tipo A	EC	29	21	7	12
		No EC	155	76	45	43
			184	97	52	55
PS $\geq$ 140	Tipo B	EC	8	9	3	7
		No EC	171	62	31	14
			179	71	34	21
PS < 140	Tipo A	EC	41	24	27	17
		No Ec	599	277	140	116
			640	301	167	133
PS < 140	Tipo B	EC	20	16	13	3
		No EC	669	320	139	80
			689	336	152	83

- a) Ajustar un modelo logit simple para explicar la probabilidad de padecer enfermedad coronaria en función del número de cigarrillos diarios fumados. Contrastar la bondad del ajuste del modelo, construir intervalos de confianza para sus parámetros e interpretarlos en términos de cocientes de ventajas tanto con el método parcial como con el método marginal para construir las variables del diseño.
- b) Encontrar mediante selección stepwise el modelo logit más adecuado para explicar la probabilidad de EC en términos de las tres variables explicativas consideradas. Hacer una validación completa del modelo seleccionado e interpretar sus parámetros. Considerar la posibilidad de que haya interacción entre las variables explicativas.
8. Se quiere explicar la probabilidad de padecer cáncer de esófago en la población francesa. Para ello se ha realizado un estudio en el que se consideran como variables explicativas el consumo de alcohol (alto, bajo) y la edad agrupada en intervalos de diez años. Consumo alto de alcohol significa un litro de vino o más al día. Para explicar la probabilidad de padecer cáncer de pulmón se ajustará un modelo logit en el que

el consumo de alcohol se considerará una variable categórica binaria y la edad una variable continua cuyos valores son las marcas de clase de cada intervalo. Se considerará también que no hay interacción entre ambas variables.

Edad	Alcohol	Cáncer esófago	
		Si	No
25-34	Alto	1	9
	Bajo	0	106
35-44	Alto	4	26
	Bajo	5	164
45-54	Alto	25	29
	Bajo	21	138
55-64	Alto	42	27
	Bajo	34	139
65-74	Alto	19	18
	Bajo	36	88
75-84	Alto	5	0
	Bajo	8	31

- a) Encontrar mediante selección stepwise el modelo logit más adecuado para explicar la probabilidad de padecer cáncer de esófago en términos de las dos variables explicativas consideradas. Explicar detalladamente el tipo de contrastes condicionales de razón de verosimilitudes realizados en cada paso.
 - b) Hacer una validación completa del modelo seleccionado mediante el contraste global de bondad de ajuste y el análisis de sus residuos, indicando en cada momento las hipótesis de los contrastes utilizados así como sus estadísticos y distribuciones en las que se basan .
 - c) Interpretar los parámetros del modelo seleccionado en términos de cocientes de ventajas, contrastar su significación estadística y construir intervalos de confianza del 99 % para dichos cocientes de ventajas.
 - d) Elegir basándose en la tasa de clasificaciones correctas la probabilidad óptima (*cutpoint*) para decidir si una persona padecerá o no cáncer de esófago en función de la probabilidad estimada por el modelo, explicando en que consiste el procedimiento utilizado.
9. Para estudiar los efectos del tratamiento con AZT para retrasar la aparición de los síntomas del SIDA, se realizó un estudio, publicado

en el New York Times (15-2-1991), con 338 infectados por SIDA cuyo sistema inmunitario estaba comenzando a fallar. Estos enfermos fueron elegidos aleatoriamente para recibir AZT inmediatamente después de la aparición de los primeros síntomas (AZT=si) o después de esperar un tiempo hasta que su sistema inmune estaba muy debilitado (AZT=no). Se controlará a su vez la raza (negra=0, blanca=1) para predecir la probabilidad de desarrollar el SIDA. Los datos del estudio figuran en la siguiente tabla:

		Síntomas de SIDA	
Raza	AZT	Si	No
Blanca	Si	14	93
	No	32	81
Negra	Si	11	52
	No	12	43

- a) Obtener la expresión matricial de las ecuaciones de verosimilitud de del modelo de regresión logística múltiple obtenido considerando las dos variables explicativas, AZT y Raza. Resolverlas de forma aproximada usando el método de Newton-Raphson y obtener como consecuencia el valor aproximado de los estimadores MV de los parámetros del modelo y de su matriz de covarianzas estimada.
 - b) Seleccionar el modelo logit más adecuado para predecir la probabilidad de desarrollar los síntomas del SIDA en función del tratamiento con AZT y de la raza. Contrastar la bondad del ajuste del modelo y analizar sus residuos.
 - c) Razonar si la raza es un factor de confusión para el análisis de la asociación entre AZT y los síntomas del SIDA.
 - d) Interpretar los parámetros del modelos en base a cocientes de ventajas y proporcionar para ellos intervalos de confianza del 99%. Estimar, además, el riesgo de desarrollar el SIDA para los tratados con AZT con respecto a los no tratados.
10. Para determinar la opinión sobre la gestión de la sanidad (pública, privada) en base a la clase social (alta, media, baja), el sexo (mujer, hombre) y la edad (< 40 , $40 - 65$, > 65), se ha realizado una encuesta cuyos datos se recogen en la siguiente tabla:

Sexo	Edad	Clase social	Gestión	
			Pública	Privada
Mujer	< 40	Alta	23	15
		Media	44	44
		Baja	24	27
	40 – 65	Alta	28	18
		Media	43	18
		Baja	28	16
	> 65	Alta	22	19
		Media	23	21
		Baja	27	7
Hombre	< 40	Alta	40	50
		Media	76	45
		Baja	40	18
	40 – 65	Alta	9	5
		Media	47	44
		Baja	77	55
	> 65	Alta	28	22
		Media	9	13
		Baja	30	12

- a) Construir mediante selección stepwise el modelo logit más adecuado para explicar la probabilidad de preferir la sanidad pública en términos de las variables sexo, edad y clase social. Teniendo en cuenta que el objetivo de este análisis es ver si la clase social determina la opinión sobre la gestión de la sanidad, ¿son el sexo y la edad factores de confusión?
 - b) Contrastar la bondad del ajuste del modelo estimado mediante el test más adecuado. Validar el modelo mediante un análisis de residuos y calcular el valor del cutpoint que lleva a la máxima tasa de clasificaciones correctas.
 - c) Interpretar la exponencial de sus parámetros en términos de cocientes de ventajas y calcular intervalos de confianza del 99%. Predecir además la probabilidad de preferir la sanidad privada para una persona de clase alta.
11. La siguiente tabla representa un estudio de casos y controles sobre los efectos de fumar cigarrillos y beber café sobre el infarto de miocardio en una muestra de hombres menores de 55 años:

Cigarrillos por día	Tazas de café por día	Infarto de miocardio (I)	
		Caso	Control
0	0	66	123
	1 – 2	141	179
	3 – 4	113	106
	≥ 5	129	80
1 – 24	0	30	52
	1 – 2	59	45
	3 – 4	63	65
	≥ 5	102	58
25 – 34	0	15	12
	1 – 2	53	22
	3 – 4	55	16
	≥ 5	118	44
≥ 35	0	36	13
	1 – 2	69	25
	3 – 4	119	30
	≥ 5	373	85

Para predecir la probabilidad de padecer un infarto (caso) en función del número de cigarrillos y tazas de café diarios consumidos se ha estimado un modelo logit tratando estas dos variables explicativas como factores cualitativos y utilizando el método parcial de codificación respecto a la primera categoría. En base a los resultados del ajuste con el programa BMDP que se presentan a continuación se pide:

- Utilizar el procedimiento de selección "stepwise" basado en contrastes condicionales de razón de verosimilitudes para seleccionar el modelo logit que mejor se ajusta a estos datos.
- Contrastar la bondad del ajuste del modelo seleccionado mediante el test más adecuado. Interpretar la exponencial de sus parámetros en términos de cocientes de ventajas, contrastar su significación estadística y calcular intervalos de confianza del 99 %.
- Validar el modelo mediante un análisis de residuos y calcular el valor del cutpoint que lleva a la máxima tasa de clasificaciones correctas. Calcular para el cutpoint seleccionado la tasa de verdaderos positivos y de falsos negativos.
- Predecir la probabilidad de padecer infarto para un hombre no fumador que no toma café y la de no padecerlo para un hombre que fuma de 1 a 24 cigarrillos diarios y bebe más de cinco tazas de café al día.

12. Con objeto de estudiar la relación entre las muertes por leucemia durante 1950-1970 y la dosis de radiación emitida por la bomba atómica del final de la Segunda Guerra Mundial, se ha realizado un muestreo estratificado de acuerdo a la edad de los individuos en el momento del lanzamiento de la bomba. Los datos asociados a las variables M=muerte por leucemia, E = edad y D = dosis de radiación, aparecen en la siguiente tabla:

Edad	Muerte	Dosis de radiación atómica					
		0	0-9	10-49	50-99	100-199	> 200
0-9	Si	0	7	3	1	4	11
	No	5015	10752	2989	694	418	387
10-19	Si	5	4	6	1	3	6
	No	5973	11811	2620	771	792	820
20-34	Si	2	8	3	1	3	7
	No	5669	10828	2798	797	596	624
35-49	Si	3	19	4	2	1	10
	No	6158	12645	3566	972	694	608
> 50	Si	3 6 7	3	2	2	6	
	No	3695	9053	2415	655	393	289

Para predecir la probabilidad de morir de leucemia ($Y=1$) en función de la dosis de radiación atómica y la edad, se ha estimado un modelo logit en el que se consideran las dos covariables como factores cualitativos y se utiliza el método parcial de codificación respecto a la primera categoría.

- Utilizar el procedimiento de selección "stepwise" basado en contrastes condicionales de razón de verosimilitudes para seleccionar el modelo logit que mejor se ajusta a estos datos.
- Contrastar la bondad del ajuste del modelo seleccionado mediante el test más adecuado. Contrastar la significación estadística de sus parámetros, interpretar su exponencial en términos de cocientes de ventajas y calcular intervalos de confianza del 99 %. para los cocientes de ventajas.
- Validar el modelo mediante un análisis de residuos y medidas de influencia.
- Interpretar la exponencial del parámetro constante y estimar a partir de ella la probabilidad de morir por leucemia en el caso de radiación nula. Estimar también la probabilidad de no morir por

leucemia para un individuo de 23 años y expuesto a una dosis 150 de radiación.

- e) Construir un test de diagnóstico que maximice la sensibilidad o tasa de verdaderos positivos. Estimar el nivel de radiación para el que la probabilidad de muerte coincide con el cut-point del test.